

ĐỒ ÁN BIG DATA · ARXIV:2410.17266

Temporal Relational Reasoning of Large Language Models for Stock Price Prediction

Temporal Relational Reasoning + Retrieval-Augmented Generation, zero-shot trên dòng tin tài chính.

NHÓM


Nhóm 1

THÀNH VIÊN

Dương Trọng Nguyên · Nguyễn Ngọc Bình An

HỌC KỲ

HK2 · 2025–2026



Vấn đề & Động lực

- Thị trường = dữ liệu **khối lượng lớn, tốc độ cao, đa dạng** → đúng bài toán Big Data.
- Dự đoán **hướng giá** $\approx$ bất khả thi (thị trường hiệu quả dạng yếu).
- Nhưng **rủi ro crash** mang tín hiệu rõ từ TIN TỨC — tâm lý, sự kiện, lan truyền.
- **Use case:** cảnh báo sớm rủi ro — advisory, không phải lệnh mua–bán.

**Hướng giá
(lên / xuống)**
 $\approx$ Ngẫu nhiên (EMH)



**Rủi ro crash
(tail-risk)**
✓ Có tín hiệu từ tin tức

Bài toán — định nghĩa chính xác

ĐẦU VÀO

Dòng tin tài chính theo ngày cho 6 cổ phiếu: **AAPL · AMZN · GOOGL · NVDA · TSLA · NFLX**.

NHÃN


Từ giá lịch sử OHLCV — ngày crash nếu low 3 ngày tới $\leq -6\%$.

ĐẦU RA

P(danh mục equal-weight giảm $\geq 6\%$ trong 3 ngày tới) cho mỗi ngày.

ĐÁNH GIÁ

AUROC / PR-AUC. Nhân quả: chỉ dùng quá khứ (embargo ≥ 3 ngày).



LLM suy luận, không huấn luyện

~~Train mô hình dự báo~~

Không có pha huấn luyện lại



LLM suy luận zero-shot

Đọc & lập luận trên đồ thị

- Mô hình **zero-shot** — không huấn luyện lại, chỉ đọc và lập luận.
- Phỏng theo khung **TRR** (Temporal Relational Reasoning) của bài báo gốc.
- Chỉ một **meta-learner nhỏ** học trên đặc trưng dẫn xuất; giá cung cấp nhãn.


Khung TRR — bốn pha

Ví dụ xuyên pipeline | "Sàn giao dịch lớn bị hack — BTC, ETH lao dốc, lan truyền thanh lý"

1 Brainstorm

Tin → đồ thị tác động: "X tác động ±Y", có trọng số.


Ví dụ → "hack" tạo cạnh NEWS→BTC, NEWS→ETH.



2 Memory

Bộ nhớ phân rã $R = \exp(-t \cdot \lambda)$ — tin xấu nhạt dần.


Ví dụ → tin xấu vẫn nâng rủi ro 4-5 ngày sau rồi mờ dần.



3 Attention

PageRank cắt tỉa xuống top-k cạnh gần danh mục nhất.


Ví dụ → giữ 2 cạnh gần BTC/ETH; loại thực thể nhiễu.



4 Reason

LLM suy luận trên đồ thị con → xác suất crash.

Ví dụ → $P(\text{crash}) = 0,89$.



Temporal: Bộ nhớ mang tác động xấu sang ngày kế tiếp rồi phân rã dần theo thời gian.

RAG — hai vai trò

1 · Chọn lọc

Từ kho tin lớn mỗi ngày, lấy k tin liên-quan-danh-mục nhất → LLM chỉ đọc phần giới hạn.

Kho tin ~4,5 triệu bài

▼ RAG select


k ≈ 20 tin / ngày



LLM

2 · Few-shot lịch sử

Truy hồi các ngày quá khứ tương tự + kết cục thật → chèn vào prompt.




"Hôm nay giống ngày crash nào trong quá khứ?"

⚡ Corpus cỡ GB nhưng chi phí LLM vẫn $O(\text{số_ngày} \times k)$ — hoàn toàn nhân quả.

Dữ liệu — hai nguồn tin lịch sử

Số bài tin trong corpus 2016–2023 — tổng 4,5 triệu

- Analyst-ratings** · Gọn · tuyển khớp danh mục
3 file ~886 MB → 6 mã = 9.872 dòng → headline 0,785 / 0,847 / 0,710
 - FNSPID** · **Đồ sộ** · **Big Data** toàn thị trường
23 GB / 15,7 triệu → 12 GB / 4,5 triệu → mở rộng Big Data 0,615 / 0,652
 - Giá OHLCV**
6 mã · 2.012 ngày → sinh nhãn crash
 - Tin trực tiếp**
~500 tin/ngày (yfinance + Google News) → triển khai live
- Bài học:** nguồn lớn KHÔNG vượt bộ nhỏ đã tuyển khớp danh mục.



Năm chữ V của Big Data

V

Volume

23 GB / 15,7 triệu bài → 12 GB / 4,5 triệu bài

V

Velocity

Luồng trực tiếp ~500 tin/ngày · cập nhật 60 s · Spark Streaming

V

Variety

Tin công ty · vĩ mô · crypto · thế giới · giá — nhiều nguồn

V

Value

Advisory cảnh báo crash + web app triển khai thật

V

Veracity

Khử trùng lặp + lọc theo danh mục + embargo 3 ngày — nhân quả, không rò rỉ tương lai

Lưu trữ lớn — nạp vào LLM tối thiểu

KHO GỐC
Corpus 12 GB · 4,5 triệu bài

CHỈ MỤC TRUY HỒI
SQLite theo ngày
1,9 GB · 44 ms / ngày

PHỤC VỤ LLM
Phần RAG ~2 MB

- **Stream-and-filter** — không bao giờ lưu 23 GB thô.
- Đọc theo khối (RAM-bounded) · chiều cột · chỉ mục phân vùng · chọn lọc RAG.
- Dữ liệu dẫn xuất **tái tạo 100% từ code** — không lưu kèm dữ liệu nặng.

Apache Spark — ETL & truy vấn




- 12 GB CSV → **718 MB Parquet / 101 giây**, phân vùng theo năm.
- Truy vấn 4,5 triệu dòng / 2,4 s · partition pruning **year=2020** trong 0,2 s.
- Cùng code chạy cluster: chỉ đổi **SPARK_MASTER**.

Thời gian đọc — ~40× nhanh hơn



Fan-out 40 shard trên pool GPU

40 shard song song trên pool GPU (20 base + 20 RAG)



Mỗi shard ~101 ngày + **kho ngày lịch sử đầy đủ (lookback)** — giữ nhân quả khi chia theo ngày.

Wall-clock — rút gọn ~15×

Tuần tự 1 GPU

≈ 5 giờ

40 shard song song

≈ 20 phút

= Chạy 1 máy cho kết quả Y HẾT → phân tán chỉ để TĂNG TỐC.

Triển khai & Demo trực tiếp

Web app Streamlit (live)

Gauge xác suất crash + feed ~500 tin/ngày · biểu đồ tương tác

Mô hình

Qwen2.5-**32B** (Kaggle, offline, backtest) ·
7B-AWQ (cục bộ, live)

FastAPI + daemon

/predict · /backtest · 60 s · rolling 7 ngày



► Demo trực tiếp



Quét để xem trực tiếp

Hiển thị $\neq$ Dự đoán

FEED HIỂN THỊ



Dự đoán **chỉ dùng tin công ty + vĩ mô**.

Crypto / thế giới bị **loại trước khi suy luận**.


Tin trực tiếp không có nhãn → chứng minh **triển khai**, không phải độ chính xác.

Kết quả chính — toàn corpus 8 năm

AUROC

----- Ngẫu nhiên · 0,50

- **Toàn corpus FNSPID 2016–2023** (78 sự kiện / 8 năm): base 0,615 → RAG **0,652**; lift **+0,037**, **p = 0,047** → có ý nghĩa thống kê.
- RAG có ý nghĩa trên **CẢ HAI corpus**: analyst-news +0,074 (p=0,009) **và** FNSPID +0,037 (p=0,047).
- **Best-case** (panic COVID, analyst-news): 0,785 → +RAG **0,847**.
- Baseline "khối lượng tin": **mạnh trên FNSPID (0,66)**, gần ngẫu nhiên analyst-news (~0,50) — đối chiếu slide 15.



Đối chiếu trên cùng cửa sổ & tính nhất quán

Cửa sổ (FNSPID)	Base	RAG	p-value	News-vol
COVID analyst-news cũ: 0,785 / 0,847	0,707	0,763	0,082	0,656
Rộng 2016–2020 lát cắt hẹp · phẳng	0,693	0,681	0,66	0,677
Toàn bộ 2016–2023 78 sự kiện · 8 năm	0,615	0,652	0,047 ✓	0,662

Đối chiếu 1 — news-volume phụ thuộc vào corpus
Gần ngẫu nhiên (~0,50) trên analyst-news, nhưng **mạnh (0,66) trên FNSPID** vì số tin/ngày phản ánh mức chú ý thị trường → **vì thế kiểm thử / đánh giá cả hai nguồn.**

Đối chiếu 2 — RAG giúp ở nơi có tiền lệ sạch
Có ý nghĩa trên analyst-news (+0,074, p=0,009) **và** toàn FNSPID (+0,037, p=0,047); chỉ *phẳng* ở lát cắt hẹp 2016–2020 (small-N) — đúng luận điểm.

Phân tích trung thực

Điều đã hoạt động

- ✓ RAG cải thiện **có ý nghĩa thống kê** nơi có tiền lệ sạch (analyst-news +0,074, $p=0,009$; toàn corpus +0,037, $p=0,047$).
- ✓ **Bảng chứng N-lớn**: crash_prob tương quan âm với độ sâu sụt giá trên 1.860 ngày (RAG -0,104, $p<1e-4$).
- ✓ Stream → index → select cho corpus 23 GB.
- ✓ Spark + pool GPU (40 shard) chạy thật.

Giới hạn / kết quả âm

- ✗ **Small-N là trần**: chỉ 14–82 ngày crash (~4%).
- ✗ Graph-RAG đa bước, hướng 3 lớp, OHLCV volume, meta-RAG — không tăng.
- ✗ **Bẫy Big Data**: chọn toàn-mã làm giảm tín hiệu → đã sửa bằng lọc danh mục.

Phạm vi: Spark pseudo-distributed + pool GPU Kaggle free-tier (không phải cluster HDFS nhiều máy) — code sẵn cho cluster.

Kết luận & Hướng phát triển

FNSPID 23 GB

→

Stream / Index

→

RAG select

→

Brainstorm→Memory→Attention→Reason

→

40 shard GPU

→

AUROC

Kết luận

- TRR zero-shot + RAG dự đoán rủi ro crash từ tin tức — AUROC tốt ở cửa sổ khủng hoảng.
- **RAG cải thiện ổn định.**
- Xử lý nguồn 23 GB bằng stream-index-select + Spark + pool GPU phân tán.

Hướng phát triển

- Cluster Spark / HDFS nhiều máy thật.
- Corpus đa nguồn: mạng xã hội, filing.
- Hiệu chỉnh xác suất & ngưỡng theo chi phí · mở rộng đa tài sản.

Q&A

Cảm ơn thầy/cô và các bạn đã lắng nghe!

repo github.com/duongtrongnguyen123/bigdata-stock-crash-trr



Quét để xem mã nguồn